


Задание к семинарам №9 и №10

Выполнила Макаркина Татьяна Сергеевна

Задание 1

Я развернула кластер DataProc. Перед этим был создан бакет Object Storage, выданы необходимые роли сервисному аккаунту, настроена группа безопасности, облачную сеть. Так выглядит карта моей облачной сети:




Кластер в рабочем состоянии:

The screenshot shows the 'Yandex Data Processing / Кластеры / dataproc877' (Yandex Data Processing / Clusters / dataproc877) interface. The left sidebar contains navigation links: 'Обзор' (Overview), 'Подкластеры' (Subclusters), 'Хосты' (Hosts), 'Операции' (Operations), 'Мониторинг' (Monitoring), 'Права доступа' (Access rights), 'Логи' (Logs), 'Топология' (Topology), 'Задания' (Jobs), 'Документация' (Documentation), 'Как устроен кластер в Yandex Data Processing' (How the cluster is structured in Yandex Data Processing), and 'Классы хостов для кластеров' (Host classes for clusters). The main area displays the cluster details for 'dataproc877'. The 'Обзор' (Overview) tab is active, showing the cluster status as 'Alive'. The 'Доступность' (Availability) section shows 'Alive' and a message: 'Все хосты работают нормально, все запущенные операции были успешно выполнены.' (All hosts are working normally, all running operations were successfully completed). The 'Настройки' (Settings) section shows the cluster version as '2.1', the availability zone as 'ru-central1-b', and the services as 'HDFS, MAPREDUCE, SPARK, TEZ, YARN, ZEPPELIN'. A price summary on the right indicates a cost of '30,91 ₽ в час' (30.91 RUB per hour) and lists the resources: 'Вычислительные ресурсы обычной ВМ, Intel Ice Lake, 100% vCPU' (12,40 RUB) and 'Yandex Data Processing. Вычислительные ресурсы хостов, Intel Ice Lake, 100% vCPU' (1,38 RUB). A notification banner at the top right states: 'С 1 мая 2026 года изменилась стоимость ряда сервисов. Подробнее в блоге' (Starting May 1, 2026, the cost of a number of services has changed. Read more in the blog).

Теперь необходимо подготовить JSON-файл. Возьмем этот:

```
trueef@Foxik:/mnt/d/Dz$ nano example.json
trueef@Foxik:/mnt/d/Dz$ cat example.json
{
  "pets": [
    {
      "name" : "Purrscloud",
      "species" : "Cat",
      "favFoods" : "wet food",
      "birthYear" : 2016,
      "photo" : "https://learnwebcode.github.io/json-example/images/cat-2.jpg"
    },
    {
      "name" : "Barksalot",
      "species" : "Dog",
      "birthYear" : 2008,
      "photo" : "https://learnwebcode.github.io/json-example/images/dog-1.jpg"
    },
    {
      "name" : "Meowsalot",
      "species" : "Cat",
      "favFoods" : "tuna",
      "birthYear" : 2012,
      "photo" : "https://learnwebcode.github.io/json-example/images/cat-1.jpg"
    }
  ]
}
```



Файл положила в бакет Object Storage. С файлом буду работать через Zeppelin.

В первой ячейке я импортировала необходимые инструменты. Во второй - прочитала JSON из бакета и разложила его в нужный формат

The screenshot shows the Zeppelin Notebook interface. The top bar includes the Zeppelin logo, 'Notebook' dropdown, 'Job' status, a search bar, and 'anonymous' user indicator. The notebook title is 'Dz Spark'. There are two code cells. The first cell contains the import statement: `%spark.pyspark import pyspark.sql.functions as F`. The second cell contains code to read a JSON file from S3, explode the 'pets' field, and show the result. The output of the second cell is a table with columns: birthYear, favFoods, name, photo, species. The table contains three rows of data.

```
%spark.pyspark
import pyspark.sql.functions as F

%spark.pyspark
input_path = "s3a://for-dataproc-tat/example.json"

df = spark.read \
    .option("multiline", "true") \
    .json(input_path)

explode_pets = df.select(F.explode('pets'))
pets = explode_pets.select('col.*')
pets.show()
```

birthYear	favFoods	name	photo	species
2016	wet food	Purrscloud	https://learnwebc...	Cat
2008	null	Barksalot	https://learnwebc...	Dog
2012	tuna	Meowsalot	https://learnwebc...	Cat

Теперь осталось только записать все в parquet-файл и сохранить в бакет:

```
%spark.pyspark
pets.write.parquet("s3a://for-dataproc-tat/pets.parquet")
```

SPARK JOB FINISHED

Took 5 sec. Last updated by anonymous at May 06 2026, 7:10:59 PM.

```
%spark.pyspark
```

READY

Проверяю в бакете - объекты появились:

Объекты

Поиск по началу имени объекта, включая префикс

☐	Имя	Размер	Класс хранилища	Последнее изменение	Метки	⚙
☐	📁 pets.parquet	—	—	—	—	...
☐	📄 example.json	590 Б	Стандартное	06.05.2026, в 19:10	—	...

Объекты

Поиск по началу имени объекта, включая префикс

☐	Имя	Размер	Класс хранилища	Последнее изменение	⚙
☐	📄 _SUCCESS	11.85 КБ	Стандартное	06.05.2026, в 19:10	...
☐	📄 part-00000-da7a36af-5b16-44c2-81f1-bb00f65386bd-c000.sn...	1.81 КБ	Стандартное	06.05.2026, в 19:10	...



Еще раз выведу конечные данные после разложения:

```
pets.show()
```

birthYear	favFoods	name	photo	species
2016	wet food	Purrscloud	https://learnwebc...	Cat
2008	null	Barksalot	https://learnwebc...	Dog
2012	tuna	Meowsalot	https://learnwebc...	Cat

Задание 2

Я развернула два кластера, необходимых для работы: Managed Service for Kafka и Yandex StoreDoc. В Kafka создала топик sensors



Установила локально в WSL утилиту `kafkacat` (она же `kcat`) и с ее помощью подключаюсь к топику:

```
truef@Foxik:/mnt/d/Dz$ kcat -C \
-b rc1b-u4ds9ssqpkld5os.mdb.yandexcloud.net:9091 \
-t sensors \
-X security.protocol=SASL_SSL \
-X sasl.mechanism=SCRAM-SHA-512 \
-X sasl.username="mkf-user" \
-X sasl.password="admin123" \
-X ssl.ca.location=/usr/local/share/ca-certificates/Yandex/YandexInternalRootCA.crt \
-Z
% Reached end of topic sensors [0] at offset 0
% Reached end of topic sensors [2] at offset 0
% Reached end of topic sensors [1] at offset 0
% Reached end of topic sensors [5] at offset 0
% Reached end of topic sensors [8] at offset 0
% Reached end of topic sensors [11] at offset 0
% Reached end of topic sensors [4] at offset 0
% Reached end of topic sensors [7] at offset 0
% Reached end of topic sensors [10] at offset 0
% Reached end of topic sensors [3] at offset 0
% Reached end of topic sensors [6] at offset 0
% Reached end of topic sensors [9] at offset 0
```

Далее необходимо подготовить файл с тестовыми данными:

```
truef@Foxik:/mnt/d/Dz$ cat example.json
{
  "device_id": "iv9a94th6rzt*****",
  "datetime": "2020-06-05 17:27:00",
  "latitude": 55.70329032,
  "longitude": 37.65472196,
  "altitude": 427.5,
  "speed": 0,
  "battery_voltage": 23.5,
  "cabin_temperature": 17,
  "fuel_level": null
}
```

