


Задание к семинарам №9 и №10

Выполнила Макаркина Татьяна Сергеевна

Задание 1

Я развернула кластер DataProc. Перед этим был создан бакет Object Storage, выданы необходимые роли сервисному аккаунту, настроена группа безопасности, облачную сеть. Так выглядит карта моей облачной сети:




Кластер в рабочем состоянии:

The screenshot shows the 'Yandex Data Processing / Кластеры / dataproc877' (Yandex Data Processing / Clusters / dataproc877) overview page. The cluster is in an 'Alive' state. The left sidebar contains navigation links: 'Обзор' (Overview), 'Подкластеры' (Subclusters), 'Хосты' (Hosts), 'Операции' (Operations), 'Мониторинг' (Monitoring), 'Права доступа' (Access rights), 'Логи' (Logs), 'Топология' (Topology), 'Задания' (Jobs), 'Документация' (Documentation), 'Как устроен кластер в Yandex Data Processing' (How the cluster is structured in Yandex Data Processing), and 'Классы хостов для кластеров' (Host classes for clusters). The main content area is divided into three sections: 'Обзор' (Overview), 'Доступность' (Availability), and 'Настройки' (Settings). The 'Обзор' section shows the cluster's identifier, name, creation date, environment, service account, and bucket. The 'Доступность' section shows the cluster is 'Alive' and that all hosts are working normally. The 'Настройки' section shows the cluster's version, zone, services, and other configuration details. On the right, there's a sidebar with pricing information: '30,91 ₽ в час' (30.91 RUB per hour) and a list of resources and their costs.

Ресурс	Цена
Вычислительные ресурсы обычной ВМ, Intel Ice Lake, 100% vCPU	12,40 ₽
Yandex Data Processing. Вычислительные ресурсы хостов, Intel Ice Lake, 100% vCPU	1,38 ₽
Вычислительные ресурсы обычной ВМ, Intel Ice Lake, RAM	13,20 ₽
Yandex Data Processing.	

Теперь необходимо подготовить JSON-файл. Возьмем этот:

```
trueef@Foxik:/mnt/d/Dz$ nano example.json
trueef@Foxik:/mnt/d/Dz$ cat example.json
{
  "pets": [
    {
      "name" : "Purrscloud",
      "species" : "Cat",
      "favFoods" : "wet food",
      "birthYear" : 2016,
      "photo" : "https://learnwebcode.github.io/json-example/images/cat-2.jpg"
    },
    {
      "name" : "Barksalot",
      "species" : "Dog",
      "birthYear" : 2008,
      "photo" : "https://learnwebcode.github.io/json-example/images/dog-1.jpg"
    },
    {
      "name" : "Meowsalot",
      "species" : "Cat",
      "favFoods" : "tuna",
      "birthYear" : 2012,
      "photo" : "https://learnwebcode.github.io/json-example/images/cat-1.jpg"
    }
  ]
}
```



Файл положила в бакет Object Storage. С файлом буду работать через Zeppelin.

В первой ячейке я импортировала необходимые инструменты. Во второй - прочитала JSON из бакета и разложила его в нужный формат

The screenshot shows the Zeppelin Notebook interface. The top bar includes the Zeppelin logo, 'Notebook', 'Job', a search bar, and a user dropdown 'anonymous'. The notebook title is 'Dz Spark'. There are two code cells. The first cell contains the import statement: `%spark.pyspark import pyspark.sql.functions as F`. The second cell contains code to read a JSON file from S3, explode the 'pets' field, and show the result. The output of the second cell is a table with columns: birthYear, favFoods, name, photo, species. The table contains three rows of data.

```
%spark.pyspark
import pyspark.sql.functions as F

Took 0 sec. Last updated by anonymous at May 06 2026, 7:10:42 PM.

%spark.pyspark
input_path = "s3a://for-dataproc-tat/example.json"

df = spark.read \
    .option("multiline", "true") \
    .json(input_path)

explode_pets = df.select(F.explode('pets'))
pets = explode_pets.select('col.*')
pets.show()

+-----+-----+-----+-----+-----+
|birthYear|favFoods|  name|  photo|species|
+-----+-----+-----+-----+-----+
|    2016|wet food|Purrscloud|https://learnwebc...|  Cat|
|    2008|   null|Barksalot|https://learnwebc...|  Dog|
|    2012|   tuna|Meowsalot|https://learnwebc...|  Cat|
+-----+-----+-----+-----+-----+

Took 0 sec. Last updated by anonymous at May 06 2026, 7:10:46 PM.
```

Теперь осталось только записать все в parquet-файл и сохранить в бакет:

```
%spark.pyspark
pets.write.parquet("s3a://for-dataproc-tat/pets.parquet")
```

SPARK JOB FINISHED

Took 5 sec. Last updated by anonymous at May 06 2026, 7:10:59 PM.

```
%spark.pyspark
```

READY

Проверяю в бакете - объекты появились:

Объекты

Поиск по началу имени объекта, включая префикс

☐	Имя	Размер	Класс хранилища	Последнее изменение	Метки	⚙
☐	 pets.parquet	—	—	—	—	...
☐	 example.json	590 Б	Стандартное	06.05.2026, в 19:10	—	...

Объекты

Поиск по началу имени объекта, включая префикс

☐	Имя	Размер	Класс хранилища	Последнее изменение	⚙
☐	 _SUCCESS	11.85 КБ	Стандартное	06.05.2026, в 19:10	...
☐	 part-00000-da7a36af-5b16-44c2-81f1-bb00f65386bd-c000.sn...	1.81 КБ	Стандартное	06.05.2026, в 19:10	...

Еще раз выведу конечные данные после разложения:

```
pets.show()
```

birthYear	favFoods	name	photo	species
2016	wet food	Purrscloud	https://learnwebc...	Cat
2008	null	Barksalot	https://learnwebc...	Dog
2012	tuna	Meowsalot	https://learnwebc...	Cat

Задание 2

Я развернула два кластера, необходимых для работы: Managed Service for Kafka и Yandex StoreDoc. В Kafka создала топик sensors

cloud-truefoxik tati Managed Service for Kafka / Кластеры [Создать кластер](#)

Кластеры

Фильтр по имени или идентификатору Все зоны доступности

Имя ↑↓	Идентификатор ↑↓	Описание	Доступность ↑↓	Дата создания ↑↓	Окружение ↑↓	Метки	⚙️
kafka956	c9qfjap9n46k825n1isv	—	Alive	06.05.2026, в 22:53	PRODUCTION	—	...

cloud-truefoxik tati Yandex StoreDoc / Кластеры [Создать кластер](#)

Кластеры

Фильтр по имени или идентификатору Все зоны доступности

Имя ↑↓	Идентификатор ↑↓	Описание	Доступность ↑↓	Дата создания ↑↓	Версия ↑↓	Окружение ↑↓	Метки	⚙️
storedoc627	c9qo8t0cr0ldlj5e1s1e	—	Alive	06.05.2026, в 22:38	8.0	PRODUCTION	—	...

Установила локально в WSL утилиту `kafkacat` (она же `kcat`) и с ее помощью подключаюсь к топику:

```
truef@Foxik:/mnt/d/Dz$ kcat -C \
-b rc1b-u4ds9ssqpkld5os.mdb.yandexcloud.net:9091 \
-t sensors \
-X security.protocol=SASL_SSL \
-X sasl.mechanism=SCRAM-SHA-512 \
-X sasl.username="mkf-user" \
-X sasl.password="admin123" \
-X ssl.ca.location=/usr/local/share/ca-certificates/Yandex/YandexInternalRootCA.crt \
-Z
% Reached end of topic sensors [0] at offset 0
% Reached end of topic sensors [2] at offset 0
% Reached end of topic sensors [1] at offset 0
% Reached end of topic sensors [5] at offset 0
% Reached end of topic sensors [8] at offset 0
% Reached end of topic sensors [11] at offset 0
% Reached end of topic sensors [4] at offset 0
% Reached end of topic sensors [7] at offset 0
% Reached end of topic sensors [10] at offset 0
% Reached end of topic sensors [3] at offset 0
% Reached end of topic sensors [6] at offset 0
% Reached end of topic sensors [9] at offset 0
```

Далее необходимо подготовить файл с тестовыми данными:

```
truef@Foxik:/mnt/d/Dz$ cat example.json
{
  "device_id": "iv9a94th6rzt*****",
  "datetime": "2020-06-05 17:27:00",
  "latitude": 55.70329032,
  "longitude": 37.65472196,
  "altitude": 427.5,
  "speed": 0,
  "battery_voltage": 23.5,
  "cabin_temperature": 17,
  "fuel_level": null
}
```

Для “транспортировки данных” создаю два эндпойнта: для источника и приемника. И трансфер

cloud-truefoxik

tati

Data Transfer / Эндпоинты

Создать эндпоинт

Эндпоинты

Фильтр по имени или идентификатору

Тип

База данных

Все

Мои

Имя	Идентификатор	Статус	Тип	База данных	Описание	Дата создания	Автор	Меню
for-mongo	dtem4tsnbtm84617ro1d	Создан	Приёмник	MongoDB/Yandex StoreDoc	—	06.05.2026, в 23:30	TrueFoxik@yandex.ru	...
for-kafka	dteu6n5o5mb1ep16brj1b	Создан	Источник	Kafka	—	06.05.2026, в 23:27	TrueFoxik@yandex.ru	...
psql-tat	dtem83f24sv00o938uzf	Создан	Приёмник	PostgreSQL	—	22.02.2026, в 21:41	TrueFoxik@yandex.ru	...

cloud-truefoxik

tati

Data Transfer / Трансферы

Создать трансфер

Трансферы

Фильтр по имени трансфера или эндпоинта

База данных источ...

База данных приём...

Тип

Статус

Добавить метку

Все

Мои

Имя	Идентификатор	Источник	Приёмник	Статус	Тип
Preview kafka-mongo	dttae0v97k9l1f1k2311	Kafka • for-kafka	MongoDB/Yandex StoreDoc • for-mongo	Реплицируется	Репли

Осталось только отправить данные из локального JSON в Kafka:

```
trueuf@Foxik:/mnt/d/Dz$ jq -rc . example.json | kcat -P \
-b rc1b-u4ds9ssqpk1hd5os.mdb.yandexcloud.net:9091 \
-t sensors \
-k key \
-X security.protocol=SASL_SSL \
-X sasl.mechanisms=SCRAM-SHA-512 \
-X sasl.username="mkf-user" \
-X sasl.password="admin123" \
-X ssl.ca.location=/usr/local/share/ca-certificates/Yandex/YandexInternalRootCA.crt -Z
trueuf@Foxik:/mnt/d/Dz$
```

Проверю, появились ли данные из example.json в моей базе данных MongoDB:

cloud-truefoxik

tati

Подключения

Найти

Подключения Yandex Cloud

storedoc627

user1

db1

Коллекции

sensors

storedoc627 user1 / db1 / Редактор

storedoc627 / user1 / db1 / Редактор

1 db.sensors.find()

Выполнить

AI-ассистент

Поделиться

Результат

JSON

Таблица

Мета

Экспортировать

(1) { "_id": "iv9a94th6rzt*****-2026\05\06 23:43:46.06 +0300 MSK-{\"partition\":1,\"topic\": \"se-\"

{ "_id": "iv9a94th6rzt*****-2026\05\06 23:43:46.06 +0300 MSK-{ \"partition\":1,\"topic\": \"sensors\"}-0-1\"

\"device_id\": \"iv9a94th6rzt*****\"

\"datetime\": \"2020-06-05 17:27:00\"

\"latitude\": 55.70329032

\"longitude\": 37.65472196

\"altitude\": 427.5

\"-----\"

1 — 3

Всего строк: 3

✓ 1 db.sensors.find()

▶ Выполнить



AI-ассистент

↗ Поделиться



Результат

JSON

Таблица

Мета

⬇ Экспортировать

```
> (1) {"_id":"iv9a94th6rzt*****-2026\\-05\\-06 23:43:46.06 +0300 MSK-{"partition":1,"topic":"sens...
> (2) {"_id":"rhibbh3y08qm*****-2026\\-05\\-06 23:43:46.06 +0300 MSK-{"partition":1,"topic":"sens...
> (3) {"_id":"iv9a94th6rzt*****-2026\\-05\\-06 23:43:46.06 +0300 MSK-{"partition":1,"topic":"sens...
```